

a.

(a)

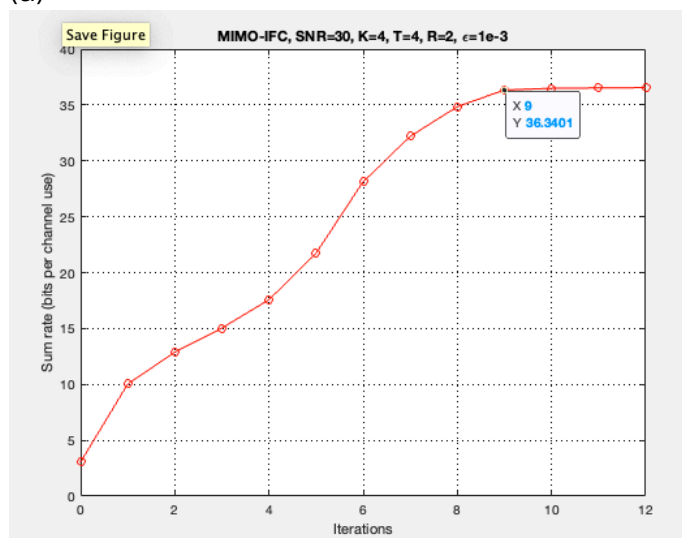


Fig 1\_a MIMO

$K = 4, T = 4, R = 2, l = 4, d = \min(4, 2) = 2,$   
 $\text{SNR} = 30 \text{ dB}$

從Fig 1\_a可以觀察到：

- 使用 WMMSE algorithm (Weighted Minimum Mean Square Error) 時，**sum-rate** 隨著迭代次數 **monotonic increase**；
- 約在第 10~12 次iteration左右趨於converge；
- 最終達到約 36.9 bits per channel use 的 sum-rate。

這與paper Fig.1(b) 的趨勢一致，驗證了 WMMSE algorithm 能夠在MIMO interference channel中快速達到穩定效能，並且reliable。

(b)




Fig 1\_b SISO

$K = 4, T = 1, R = 1, l = 4, d = \min(1, 1) = 1,$   
 $\text{SNR} = 30 \text{ dB}$

從Fig 1\_b可以觀察到：

- WMMSE algorithm 同樣展現 **monotonic increase** 特性。
- 收斂只需約 8 次迭代，快於 MIMO 情況，原因是問題維度（矩陣大小）較小。
- 最終 sum-rate 約為 9.7 bits per channel use，明顯低於 MIMO 案例。

這也對應原paper Fig.1(a) 所展示的結果，並顯示天線數量與支援的datastream直接影響 system capacity。

Conclusion:

- **Dimension Dependence**：MIMO 下，由於多天線與多datastream，WMMSE 能更有效分攤干擾並提升傳輸效率，sum-rate 高出許多；SISO 雖然效能受限，但 WMMSE 仍能快速找到接近最優的 beamforming 解。
- **Block-Coordinate Descent**: WMMSE algorithm 透過交替更新  $\mathbf{U}$  (MMSE receiver)、 $\mathbf{W}$  (weight matrix)、 $\mathbf{V}$  (beamformer) 三個，每一步都解決convex子問題，使 overall utility monotonic increase。
- 兩種情況下的收斂行為都證實了paper中指出的：**WMMSE algorithm 具有良好的 convergence，並能有效提升 multi-user interference channel的效能**

b.

比較了兩種algorithm的效能：

- **WMMSE**：WMMSE algorithm 執行一次隨機初始化
- **WMMSE 10rand int**：執行 WMMSE algorithm 共 10 次，每次不同的初始化，並選出 sum-rate 最佳結果
- SNR 從 5 dB 增加到 30 dB，間隔為 5 dB。

(a)

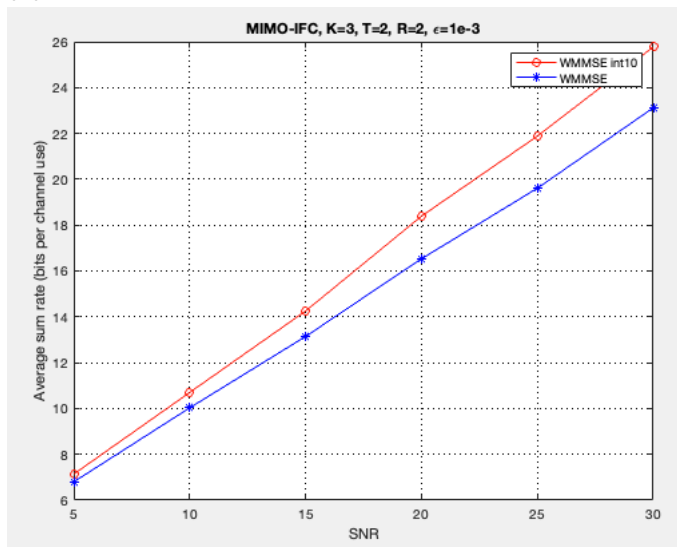


Fig 2\_a MIMO

$K = 3, T = 2, R = 2, l = 2, d = \min(2, 2) = 2$

從Fig 2\_a可以觀察到：

- 無論是 WMMSE 或 WMMSE 10rand int，average sum-rate皆隨著 SNR 呈現**線性成長趨勢**，這與Shannon Capacity Formula( $C = \log_2(1 + SNR)$ )一致。當 SNR 增加時，capacity以log速率提升。在中高 SNR 區間 (5–30 dB) 內，log曲線的曲率變小，因此在圖形上呈現近似線性的增長趨勢。

- 10次初始化效果顯著：WMMSE\_10rand\_int表現得比只做一次初始化好很多，尤其在高 SNR 區間差異明顯，顯示 WMMSE 存在 local optimum 問題，透過多次隨機初始化可以更接近 global optimum。
- 根據paper Fig. 3 的說明：「repeating the WMMSE algorithm ten times can close this performance gap」，我們的模擬結果與paper一致。透過多次隨機初始化（10 次執行），確實可以縮小 WMMSE 與最佳解之間的效能差距，有效克服演算法容易陷入 local optimum的問題。

(b)




Fig 2\_b SISO

$K = 3, T = 1, R = 1, l = 2, d = \min(1,1) = 1$

從Fig 2\_b可以觀察到：

- WMMSE vs WMMSE\_10rand\_int 幾乎重合：在 SISO 設定下，兩條曲線幾乎完全重合，顯示：WMMSE algorithm 本身幾乎能找到 global optimum
- 論文 Fig.2 說明：paper 指出：「the performance gap between single-run WMMSE and the optimal solution is small...」我們的模擬結果完全驗證了這一點。
- 由於沒有 spatial multiplexing 增益，SISO 的總傳輸率低於 MIMO 是預期之內的結果。

Conclusion:

WMMSE algorithm 是一種有效率的 block coordinate descent 方法，能在 MIMO 和 SISO 下有效地最大化sum-rate。但它存在 local optimum 問題，因此在高維MIMO 系統中建議透過 **multiple random initializations** 來避免陷入suboptimal。

c.

3.

① 目標:  $\max_V \sum_{k=1}^K \sum_{i=1}^{I_k} \alpha_{ik} R_{ik}$ , s.t.  $\sum_{i=1}^{I_k} \text{Tr}(V_{ik} V_{ik}^H) \leq P_k, \forall k=1, 2, \dots, K$

$$R_{ik} \triangleq \log \det (I + H_{ik,k} V_{ik} V_{ik}^H H_{ik,k}^H \left( \sum_{(0,j) \neq (i,k)} H_{ik,j} V_{ej} V_{ej}^H H_{ik,j}^H + \sigma_{ik}^2 I \right)^{-1})$$

② 因為 non-convex problem 很難解

從 (7) 下手

$$\min_{W, U, V} \sum_{k=1}^K \sum_{i=1}^{I_k} \alpha_{ik} (\text{Tr}(W_{ik} E_{ik}) - \log \det(W_{ik}))$$

(i) 固定  $V$ , 最佳  $U_{ik}$

$$U_{ik}^{\text{opt}} = J_{ik}^{-1} H_{ik,k} V_{ik}$$

$$J_{ik} = \sum_{j=1}^K \sum_{p=1}^{I_j} H_{ik,j} V_{ej} V_{ej}^H H_{ik,j}^H + \sigma_{ik}^2 I, \text{ closed form 代入}$$

(ii) 固定  $U_{ik}$ , 最佳  $W_{ik}$

$$\text{對 (7) 微分} \Rightarrow W_{ik}^{\text{opt}} = \underbrace{E_{ik}^{-1}}_{L(3) \text{ 定義}} \dots (19)$$

(iii) 將 (ii), (i) 代回 (7)

$$\because \text{Tr}(W_{ik} E_{ik}) = \text{Tr}(E_{ik}^{-1} E_{ik}) = d$$

$$-\log \det(W_{ik}) = -\log \det(E_{ik})$$

$$(7) \Rightarrow \min_{W, U, V} \sum_{k=1}^K \sum_{i=1}^{I_k} \alpha_{ik} (\text{Tr}(W_{ik} E_{ik}) - \log \det(W_{ik})) = \sum_{k=1}^K \sum_{i=1}^{I_k} \alpha_{ik} (d + \log \det(E_{ik}))$$

$$\Rightarrow \text{等價於 } \max_V \sum_{k=1}^K \sum_{i=1}^{I_k} \alpha_{ik} R_{ik}, \text{ 原 weighted sum rate maximization}$$

透過最佳化  $U_{ik}, W_{ik}$ , weighted sum-rate maximum problem and the minimization problem is equivalent

d.

(1).  $u_{i_k}$  (utility function)

- 嚴格遞增
- 連續可微分
- Concave function of R

(2)  $c_{i_k} = -u_{i_k}(-\log \det(E))$  (cost function)

- 嚴格遞增：E 愈小 (MSE 愈低) ，成本愈小
- 連續可微分：方便計算梯度
- strictly convex on  $E > 0$

(3)  $\gamma_{i_k} = (\nabla c_{i_k} E_{i_k})^{-1}$  (the inverse mapping of the gradient map)

- 隨W增大， $\gamma_{i_k}$  monotone變小
- continuous, bijective mapping from  $W > 0$   $E > 0$

若以上條件(1~3)成立，則 sum-utility maximization (10) 與 matrix-weighted sum-MSE minimization (12) 具有相同的 **global optimal solution**。

(4) 舉一個符合條件的  $u_{i_k}$  (proportional fairness utility)

$$u_{i_k}(R) = \log R$$

- 嚴格遞增  $\frac{du}{dR} = 1/R > 0$
- 連續可微分  $\forall R > 0$
- Concave function of R  $\frac{d^2u}{dR^2} = -1/R^2 < 0$

對應  $c_{i_k} = -u_{i_k}(-\log \det(E)) = -\log(\log \det(E))$  strictly convex on  $E > 0$

$\gamma_{i_k} = (\nabla c_{i_k} E_{i_k})^{-1}$  也滿足，所以可以確定 theorem 2 適用

e.

- (1) Robust WMMSE under Imperfect CSI：實際系統中，CSI通常是估計而來，會存在誤差。因此，可延伸paper設計Robust WMMSE，處理 CSI 誤差，採用 worst-case optimization(考慮 CSI 落在某個不確定集合中的最壞情況) 或 stochastic programming(考慮 CSI 服從某個統計分布（如高斯分布）時的期望效能最佳化) 方法。
- (2) 與機器學習結合：隨著 **Deep Learning** 與 **Reinforcement Learning** 在無線通訊中的應用，可將 WMMSE 結合學習方法，以降低計算成本與應對複雜環境，像是利用神經網路學習 **beamformer** 的設計規則，近似傳統 WMMSE 解的輸出
- (3) Multi-objective WMMSE：同時最大化 sum-rate、最小化干擾、最大化user fairness